

# Оценка влияния положения 3D КТ-снимка в пространстве на качество сегментации

Архипов Д.А., Полевой Д.В.

14 октября 2024 г.

## Аннотация

В данной работе исследуется влияние изменения ориентации 3D КТ-снимков на качество сегментации медицинских изображений с использованием модели машинного обучения. Мотивацией исследования послужила гипотеза о том, что модель сегментации, обученная на данных с фиксированной ориентацией объектов, может демонстрировать снижение точности при изменении их положения в пространстве. Для проверки гипотезы были смоделированы различные положения объектов с помощью поворотов изображений на случайные углы относительно осей, проходящих через центр объемов. Эксперименты показали, что даже очень малых поворотах вносят видимые изменения в сегментации, что подтверждает выдвинутую гипотезу. Также в работе было проанализировано влияние угла поворота на точность сегментации.

## Введение

В последние годы для сегментации медицинских изображений широко применяются методы глубокого обучения. Благодаря глубокому изучению характеристик модели могут извлекать семантическую информацию из изображений, тем самым повышая точность сегментации и гибко адаптируясь к различным наборам данных медицинских изображений и задачам. Так прорывным решением стала модель U-Net [8]. Она привнесла подход, позволивший качественно сегментировать на разных масштабах, с использованием энкодера и декодера, связанных друг с другом дополнительными соединениями. С момента появления U-Net появилось несколько улучшенных версий, включая UNet++ [13], Attention-UNet [7],

TransUNet [2] и nnU-Net [6]. Эти модели основаны на преимуществах оригинальной модели U-Net и еще больше повышают эффективность сегментации за счет добавления дополнительных слоев, внедрения механизма внимания, добавления архитектуры трансформера, грамотного объединения нескольких U-Net и других методов. Еще одной архитектурой, показавшей хорошее качество, стала DeepLab [3]. Во второй версии этой модели привнесли пирамиду ASPP, основанную на свертке с дилатацией (Atrous Convolution). Таким образом, получилось учитывать разные масштабы при сегментации изображений и повысить качество. State-of-the-art результатов в последнее время добиваются модели, построенные с учетом последних достижений в области глубокого обучения. Так можно выделить UNETR [5] и Swin-UNETR [9], энкодер которых полностью построен на архитектуре трансформера, EnsDiff [10] и MedSegDiff [11], использующие обратную диффузию для сегментации.

Для применения глубокого обучения к сегментации медицинских изображений требуется большой и разнообразный набор обучающих данных для обеспечения надежности предсказаний. Однако получение таких данных может быть затруднено из-за необходимости экспертной маркировки каждого изображения и высоких затрат на сбор большого количества. Чтобы обойти эти проблемы, аугментация данных стала эффективным методом увеличения объема и разнообразия набора обучающих данных. Особенности процесса сбора медицинских изображений, такие как вариативность положения снимаемых объектов, различия в их размерах у разных пациентов, а также использование различных аппаратов, требуют применения минимально необходимых аугментаций при обучении моделей. К таким аугментациям относятся зеркальное отражение, повороты на 90 градусов, вращение вокруг случайных осей, а также изменения контраста, яркости и насыщенности. Описание различных аугментаций и их влияния можно найти в статье [4].

В данной статье рассматривается гипотеза о том, что модели машинного обучения, используемые для сегментации медицинских изображений, могут переобучаться под конкретное положение объекта в пространстве. Это означает, что модели могут демонстрировать высокую точность сегментации на данных с фиксированной ориентацией объекта, но значительно терять в качестве при изменении его положения.

Для проверки гипотезы были проведены эксперименты по моделированию объектов в различных ориентациях в пространстве и сравнение качества сегментации между экспериментами. Для сегментации использовалась предварительно обученная модель UNETR, которая была выбрана благодаря доступной официальной реализации, предобученным весам и state-of-the-art качеству. Модель была обучена на наборе данных

ВТСВ [12], содержащем КТ-снимки и сегментации органов брюшной полости. Все изображения в наборе данных были зафиксированы в одном положении, что означает одинаковую ориентацию всех данных. Для экспериментов применялась только валидационная выборка из этого набора данных. В процессе обучения к этим объемам случайным образом применялись следующие аугментации:

- зеркальное отражение на одной из плоскостей,
- поворот на 90 градусов на одной из плоскостей,
- изменение интенсивности пикселей изображения.

Важно отметить, что в оригинальной статье авторы дополнительно использовали закрытый набор данных, что привело к более высоким результатам сегментации по сравнению с теми, которые можно получить с использованием только общедоступных весов.

## 1 Моделирование различных положений объекта в пространстве

Для моделирования различных ориентаций объекта в трёхмерном пространстве были проведены эксперименты 2—6, в которых происходили повороты изображений на разные углы вокруг произвольных осей, проходящих через центр изображения. Также для оценки влияния величины угла поворота были проведены эксперименты 0 и 1, в которых сегментация проводилась на оригинальных неповернутых объемах без и с добавлением рамки соответственно. Характеристики экспериментов представлены в таблице 1.

| Эксперимент | Диапазон углов поворота | Число поворотов | Описание                   |
|-------------|-------------------------|-----------------|----------------------------|
| 0           | —                       | —               | Ор-ые изображения          |
| 1           | —                       | —               | Ор-ые изображения с рамкой |
| 2           | $[0^\circ, 1^\circ]$    | 51              | Очень малые повороты       |
| 3           | $[1^\circ, 5^\circ]$    | 101             | Малые повороты             |
| 4           | $[5^\circ, 20^\circ]$   | 201             | Значимые повороты          |
| 5           | $[20^\circ, 45^\circ]$  | 201             | Большие повороты           |
| 6           | $[45^\circ, 180^\circ]$ | 201             | Сверхбольшие повороты      |

Таблица 1: Характеристики экспериментов с разными углами поворота

Для каждого эксперимента с поворотами было произведено свое количество операций. Оно отличается между экспериментами, так как больший диапазон угла поворота требует большего количества поворотов для

лучшего покрытия всех возможных ориентаций. Каждый поворот описывается вектором вращения  $\vec{v} = \theta \cdot \vec{e}$ , где  $\theta$  — угол поворота, а  $\vec{e}$  — единичный вектор направления оси вращения. Вектор  $\vec{e}$  генерировался путем нормализации случайного трёхмерного вектора, равномерно распределённого в диапазоне  $[-1, 1]^3$ . Угол  $\theta$  выбирался из равномерного распределения на заданном для каждого эксперимента диапазоне.

## 1.1 Реализация

Повороты изображений моделировались с помощью аффинных преобразований, реализованных с использованием объекта `Affine` из библиотеки `Monai` [1]. Для поворота изображения использовалась интерполяция `bilinear`, а для карты классов — `nearest`. Аффинные преобразования основывались на матрицах, полученных с помощью функции `Rotation.from_rotvec` из библиотеки `scipy` и сформированных на основе векторов вращения из экспериментов.

Особое внимание следует уделить этапу применения операции поворота в процессе обработки данных. В одной из стадий обработки данных авторы выполняют ресэмплинг, чтобы привести разрешение изображений к масштабу: расстояние между пикселями по осям X и Y устанавливается на 1.5 мм, а по оси Z — на 2 мм. Поворот необходимо выполнять только после этого этапа, поскольку его применение до ресэмплинга может привести к несоответствию разрешения изображения, что не соответствует условиям, на которых обучалась нейронная сеть. Также при повороте изображения возможна потеря информации из-за выхода за границы, поэтому к каждому объёму добавлялась рамка размера, предотвращающая любые возможные потери такого рода. В связи со всем с этим операции добавления рамки и поворота были включены в процесс обработки данных сразу после шага ресэмплинга.

Для оценки степени потери информации при поворотах были проведены дополнительные эксперименты. В этих экспериментах к изображениям и картам классов применялись те же аффинные преобразования, что и в основном эксперименте, после чего выполнялись обратные преобразования. Затем вычислялась ошибка между исходными и восстановленными изображениями. В качестве метрики для измерения расхождения между исходным и восстановленным изображением использовалась `MARE`, считавшаяся только по ненулевым вокселям изображения, а для оценки совпадения карт классов применялась метрика `Dice`. Обратные преобразования выполнялись с использованием функции `Affine.inverse` из библиотеки `Monai`.

## 2 Оценка влияния размера рамки на качество сегментации

В ходе работы было выявлено, что размер добавляемой рамки, которая используется для предотвращения потери информации при повороте изображений, может влиять на качество сегментации. Для исследований использовалась та же модель Unet<sub>r</sub>, основанная на архитектуре трансформера. Она выполняет сегментацию изображения с использованием скользящего окна размером  $96 \times 96 \times 96$  с 50%-ным перекрытием по площади, где каждая непересекающаяся часть размером  $16 \times 16 \times 16$  рассматривается как токен, подающийся в трансформер.

Основная гипотеза состояла в том, что некратные значения размера рамки 16 могут негативно сказываться на качестве сегментации. Для проверки данной гипотезы были проведены эксперименты, в которых сегментация выполнялась для неповернутых изображений с различными размерами рамок. Рассматривались два набора размеров рамок:  $\{0, 4, 8, 12, 16, 20\}$  и  $\{96, 100, 104, 108, 112, 116\}$ . Это позволило проанализировать не только влияние рамки, но и оценить возможное влияние скользящего окна на результаты сегментации.

Результаты экспериментов представлены в таблице 2, где жирным шрифтом выделены показатели для рамок, размеры которых кратны 16.

| Размер рамки | Mean Dice    | Mean IoU     | Mean Precision | Mean Recall  |
|--------------|--------------|--------------|----------------|--------------|
| <b>0</b>     | <b>0.774</b> | <b>0.651</b> | <b>0.818</b>   | <b>0.918</b> |
| 4            | 0.706        | 0.562        | 0.670          | 0.912        |
| 8            | 0.708        | 0.566        | 0.692          | 0.911        |
| 12           | 0.713        | 0.574        | 0.688          | 0.909        |
| <b>16</b>    | <b>0.799</b> | <b>0.680</b> | <b>0.868</b>   | <b>0.916</b> |
| 20           | 0.705        | 0.561        | 0.656          | 0.909        |
| <b>96</b>    | <b>0.768</b> | <b>0.648</b> | <b>0.811</b>   | <b>0.917</b> |
| 100          | 0.701        | 0.557        | 0.689          | 0.914        |
| 104          | 0.703        | 0.559        | 0.681          | 0.911        |
| 108          | 0.703        | 0.558        | 0.664          | 0.912        |
| 112          | 0.702        | 0.558        | 0.658          | 0.913        |
| <b>116</b>   | <b>0.771</b> | <b>0.652</b> | <b>0.832</b>   | <b>0.915</b> |

Таблица 2: Результаты сегментации с различными размерами рамок

Анализ метрик Dice, IoU и Precision из таблицы 2 демонстрирует, что использование рамок с размерами не кратными 16 действительно приводит к снижению качества сегментации. Исходя из этих наблюдений,

в эксперименте 1 применялась рамка размером 16, а в экспериментах 2—6 использовались только рамки, размеры которых кратны 16, чтобы гарантировать стабильное качество сегментации.

### 3 Результаты экспериментов по оценке потере информации при поворотах

Результаты экспериментов по оценке потери информации при поворотах представлены в таблице 3.

| Эксперимент | Диапазон углов          | MAPE  |       |       | Dice  |       |       |
|-------------|-------------------------|-------|-------|-------|-------|-------|-------|
|             |                         | Min   | Mean  | Max   | Min   | Mean  | Max   |
| 2           | $[0^\circ, 1^\circ]$    | 0.000 | 0.022 | 0.03  | 0.999 | 0.999 | 1.000 |
| 3           | $[1^\circ, 5^\circ]$    | 0.016 | 0.026 | 0.029 | 0.995 | 0.996 | 0.997 |
| 4           | $[5^\circ, 20^\circ]$   | 0.018 | 0.026 | 0.03  | 0.983 | 0.986 | 0.988 |
| 5           | $[20^\circ, 45^\circ]$  | 0.018 | 0.031 | 0.062 | 0.969 | 0.973 | 0.977 |
| 6           | $[45^\circ, 180^\circ]$ | 0.018 | 0.045 | 0.101 | 0.967 | 0.972 | 0.975 |

Таблица 3: Результаты экспериментов по оценке потери информации при поворотах

Как видно из таблицы 3, даже при небольших углах поворота  $[0^\circ, 1^\circ]$  может быть потеря информации. С увеличением угла поворота потеря информации возрастает, что отражается в увеличении MAPE для изображений и уменьшении Dice для карт классов. Тем не менее, даже при сверхбольших поворотах в диапазоне  $[45^\circ, 180^\circ]$  в среднем потеря информации остается на допустимом уровне, что говорит о корректности применяемого метода поворота изображений.

### 4 Оценка влияния положения объекта в пространстве на результат сегментации

Оценка влияния положения объекта в пространстве на результат сегментации проводилась на основе данных, полученных из экспериментов 0—6, описанных в таблице 1. Модель сегментировала повернутые изображения из каждого эксперимента, и для каждого набора данных были посчитаны метрики Dice, IoU, Precision и Recall между повернутыми истинными картами классов и сегментацией на повернутых изображениях. Все метрики считались в режиме макро, то есть усреднялись среди всех классов, исключая фон. Для каждой из метрики были подсчитаны среднее (Mean), стандартное отклонение (Std), минимум (Min), максимум

(Max), нижняя и верхняя границы уса (LW и UW), а также 25-й, 50-й и 75-й процентиля (Q1, Q2 и Q3). Все значения представлены в таблицах 4–7. Дополнительно были построены ящики с усами (boxplot) (выбросы строятся на основе межквартильного размаха с коэффициентом 1,5) для лучшей интерпретации. Графики показаны на рисунках 1–4.

| Dice |                         |       |       |       |       |       |       |       |       |       |
|------|-------------------------|-------|-------|-------|-------|-------|-------|-------|-------|-------|
| Экс. | Углы                    | Mean  | Std   | Min   | LW    | Q1    | Q2    | Q3    | UW    | Max   |
| 0    | —                       | 0.774 | 0.032 | 0.724 | 0.724 | 0.757 | 0.771 | 0.795 | 0.823 | 0.823 |
| 1    | —                       | 0.799 | 0.019 | 0.762 | 0.775 | 0.794 | 0.802 | 0.807 | 0.824 | 0.824 |
| 2    | $[0^\circ, 1^\circ]$    | 0.774 | 0.028 | 0.711 | 0.711 | 0.757 | 0.777 | 0.792 | 0.824 | 0.824 |
| 3    | $[1^\circ, 5^\circ]$    | 0.735 | 0.037 | 0.638 | 0.638 | 0.709 | 0.742 | 0.761 | 0.817 | 0.817 |
| 4    | $[5^\circ, 20^\circ]$   | 0.690 | 0.035 | 0.58  | 0.606 | 0.671 | 0.696 | 0.715 | 0.781 | 0.781 |
| 5    | $[20^\circ, 45^\circ]$  | 0.614 | 0.066 | 0.410 | 0.436 | 0.573 | 0.623 | 0.664 | 0.750 | 0.750 |
| 6    | $[45^\circ, 180^\circ]$ | 0.318 | 0.115 | 0.098 | 0.098 | 0.228 | 0.292 | 0.395 | 0.646 | 0.676 |

Таблица 4: Характеристики Dice

| IoU  |                         |       |       |       |       |       |       |       |       |       |
|------|-------------------------|-------|-------|-------|-------|-------|-------|-------|-------|-------|
| Экс. | Углы                    | Mean  | Std   | Min   | LW    | Q1    | Q2    | Q3    | UW    | Max   |
| 0    | —                       | 0.651 | 0.038 | 0.594 | 0.594 | 0.636 | 0.64  | 0.673 | 0.712 | 0.712 |
| 1    | —                       | 0.680 | 0.024 | 0.635 | 0.657 | 0.677 | 0.683 | 0.690 | 0.710 | 0.714 |
| 2    | $[0^\circ, 1^\circ]$    | 0.647 | 0.034 | 0.571 | 0.571 | 0.625 | 0.649 | 0.669 | 0.714 | 0.714 |
| 3    | $[1^\circ, 5^\circ]$    | 0.598 | 0.042 | 0.494 | 0.494 | 0.568 | 0.602 | 0.626 | 0.702 | 0.702 |
| 4    | $[5^\circ, 20^\circ]$   | 0.549 | 0.036 | 0.440 | 0.466 | 0.530 | 0.556 | 0.573 | 0.637 | 0.660 |
| 5    | $[20^\circ, 45^\circ]$  | 0.476 | 0.062 | 0.286 | 0.307 | 0.437 | 0.482 | 0.523 | 0.614 | 0.614 |
| 6    | $[45^\circ, 180^\circ]$ | 0.227 | 0.091 | 0.057 | 0.057 | 0.157 | 0.205 | 0.285 | 0.477 | 0.533 |

Таблица 5: Характеристики IoU

| Precision |                         |       |       |       |       |       |       |       |       |       |
|-----------|-------------------------|-------|-------|-------|-------|-------|-------|-------|-------|-------|
| Экс.      | Углы                    | Mean  | Std   | Min   | LW    | Q1    | Q2    | Q3    | UW    | Max   |
| 0         | —                       | 0.818 | 0.079 | 0.719 | 0.719 | 0.742 | 0.828 | 0.891 | 0.907 | 0.907 |
| 1         | —                       | 0.868 | 0.063 | 0.772 | 0.772 | 0.819 | 0.883 | 0.918 | 0.945 | 0.945 |
| 2         | $[0^\circ, 1^\circ]$    | 0.802 | 0.087 | 0.641 | 0.641 | 0.732 | 0.795 | 0.873 | 0.945 | 0.945 |
| 3         | $[1^\circ, 5^\circ]$    | 0.715 | 0.088 | 0.574 | 0.574 | 0.643 | 0.698 | 0.766 | 0.936 | 0.936 |
| 4         | $[5^\circ, 20^\circ]$   | 0.684 | 0.072 | 0.570 | 0.570 | 0.623 | 0.673 | 0.728 | 0.887 | 0.905 |
| 5         | $[20^\circ, 45^\circ]$  | 0.658 | 0.092 | 0.449 | 0.449 | 0.588 | 0.649 | 0.713 | 0.864 | 0.864 |
| 6         | $[45^\circ, 180^\circ]$ | 0.513 | 0.127 | 0.267 | 0.267 | 0.407 | 0.498 | 0.609 | 0.852 | 0.852 |

Таблица 6: Характеристики Precision

| Recall |                         |       |       |       |       |       |       |       |       |       |
|--------|-------------------------|-------|-------|-------|-------|-------|-------|-------|-------|-------|
| Экс.   | Углы                    | Mean  | Std   | Min   | LW    | Q1    | Q2    | Q3    | UW    | Max   |
| 0      | —                       | 0.839 | 0.032 | 0.791 | 0.791 | 0.815 | 0.834 | 0.857 | 0.877 | 0.877 |
| 1      | —                       | 0.856 | 0.039 | 0.777 | 0.777 | 0.831 | 0.862 | 0.884 | 0.900 | 0.900 |
| 2      | $[0^\circ, 1^\circ]$    | 0.837 | 0.041 | 0.739 | 0.739 | 0.824 | 0.837 | 0.857 | 0.887 | 0.887 |
| 3      | $[1^\circ, 5^\circ]$    | 0.811 | 0.049 | 0.696 | 0.696 | 0.787 | 0.808 | 0.832 | 0.887 | 0.887 |
| 4      | $[5^\circ, 20^\circ]$   | 0.772 | 0.047 | 0.672 | 0.672 | 0.747 | 0.766 | 0.801 | 0.857 | 0.857 |
| 5      | $[20^\circ, 45^\circ]$  | 0.717 | 0.064 | 0.527 | 0.527 | 0.676 | 0.726 | 0.761 | 0.857 | 0.857 |
| 6      | $[45^\circ, 180^\circ]$ | 0.462 | 0.125 | 0.229 | 0.229 | 0.359 | 0.420 | 0.560 | 0.762 | 0.762 |

Таблица 7: Характеристики Recall




Рис. 1: Сравнение распределений метрики Dice в экспериментах 0–6




Рис. 2: Сравнение распределений метрики IoU в экспериментах 0–6






Рис. 3: Сравнение распределений метрики Precision в экспериментах 0—6




Рис. 4: Сравнение распределений метрики Recall в экспериментах 0—6

## 4.1 Визуальное сравнение

Также были созданы изображения для визуального сравнения сегментации модели на повернутых и оригинальных снимках. Эти изображения отображают срезы, где наблюдаются наибольшие различия между сегментацией на оригинальных и повернутых данных, обведенные красной рамкой. Для анализа использовались повернутые изображения, соответствующие медианному значению Dice в каждом эксперименте.

### 4.1.1 Сравнение сегментации для эксперимента 1 с очень малыми поворотами

Срезы на рисунке 5 взяты с изображения `img0037.nii.gz`.




Рис. 5: Сравнение сегментаций для поворота на очень малый угол

### 4.1.2 Сравнение сегментации для эксперимента 2 с малыми поворотами

Срезы на рисунке 6 взяты с изображения `img0037.nii.gz`.







Рис. 6: Сравнение сегментаций для поворота на малый угол

#### 4.1.3 Сравнение сегментации для эксперимента 3 со значимыми поворотами

Срезы на рисунке 7 взяты с изображения `img0039.nii.gz`.







Рис. 7: Сравнение сегментаций для поворота на значимый угол

#### 4.1.4 Сравнение сегментации для эксперимента 4 с большими поворотами

Срезы на рисунке 8 взяты с изображения `img0039.nii.gz`.







Рис. 8: Сравнение сегментаций для поворота на большой угол

#### 4.1.5 Сравнение сегментации для эксперимента 5 со сверхбольшими поворотами

Срезы на рисунке 9 взяты с изображения `img0039.nii.gz`.






Рис. 9: Сравнение сегментаций для поворота на сверхбольшой угол

## 5 Анализ результатов

Результаты экспериментов подтверждают влияние угла поворота 3D КТ-снимков на качество сегментации, что соответствует выдвинутой гипотезе. Все метрики (минимум, максимум, среднее и т.д.) демонстрируют закономерное снижение с увеличением угла поворота. Если не учитывать последний эксперимент со сверхбольшими поворотами, то видна интересная закономерность: при очень малых и малых углах поворота Precision падает быстрее, чем Recall, в то время как для больших углов характерно падение Recall, в то время как Precision падает, но не так быстро как при меньших углах. При сверхбольших углах наблюдается самая большая деградация метрик. В результате постоянного ухудшения Precision и Recall метрики Dice и IoU, последовательно и заметно падают с увеличением угла поворота.

На диаграммах с усами (рисунки 1–4) видно, что нижние границы усов у метрик опускаются больше, чем верхние. На рисунке 10 представлено сравнение двух графиков. По оси Y отложены значения в процентах (от 0 до 100), а по оси X — номера экспериментов (для удобства будем считать, что эксперимент 0 — сегментация на неповернутых объемах с рамкой в 16 вокселей). Красный график **min IoU** показывает отношение минимального значения IoU в i-ом эксперименте к его минимальному значению в эксперименте 0. Синий график **max IoU** отражает аналогичное отношение для максимальных значений. Как видно даже при сверхбольших углах поворота **max IoU** около 80%, что нельзя сказать о **min**

**IoU.** Таким образом, при случайном повороте качество сегментации даже в лучшем случае снизится, но может остаться на приемлемом уровне, тогда как в худшем — может упасть крайне низко.




Рис. 10: Сравнение деградации минимальных и максимальных значений IoU

Визуальное сравнение сегментаций подтверждает падение метрик. Даже при малых и значимых углах поворота модель может не сегментировать некоторые объекты (срез 256 на рисунке 6, срезы 286 и 260 на рисунке 7), а также неправильно сегментировать части органов (срез 218 на рисунке 6, срезы 286 и 260 на рисунке 7). Эти тенденции проявляются и при небольших углах поворота, но менее выражены. При больших углах проблемы сегментации становятся более заметными, а при сверхбольших углах поворота деградация достигает критических уровней.

## Заключение

В данном исследовании была подтверждена гипотеза о том, что модели машинного обучения, используемые для сегментации медицинских изображений, подвержены переобучению в зависимости от ориентации объекта в пространстве. Проведенные эксперименты показали, что даже очень малые повороты изображений приводят к ухудшению качества сегментации, что особенно заметно при больших и сверхбольших углах поворота. Анализ метрик продемонстрировал закономерное снижение точности сегментации с увеличением угла поворота, что подтверждается визуальными сравнениями. Кроме того, результаты показали, что даже размер

добавляемой рамки к изображениям может негативно влиять на качество сегментации.

В будущем, для повышения устойчивости моделей к изменениям в ориентации объектов, можно изучить возможность добавления дополнительных методов аугментации и/или препроцессинга данных. Исследование подобных подходов может помочь в решении описанных в статье проблем, что, в свою очередь, позволит более эффективно использовать машинное обучение в медицинских приложениях.

## Список литературы

- [1] M. Jorge Cardoso, Wenqi Li, Richard Brown, Nic Ma, Eric Kerfoot, Yiheng Wang, Benjamin Murrey, Andriy Myronenko, Can Zhao, Dong Yang, Vishwesh Nath, Yufan He, Ziyue Xu, Ali Hatamizadeh, Andriy Myronenko, Wentao Zhu, Yun Liu, Mingxin Zheng, Yucheng Tang, Isaac Yang, Michael Zephyr, Behrooz Hashemian, Sachidanand Alle, Mohammad Zalbagi Darestani, Charlie Budd, Marc Modat, Tom Vercauteren, Guotai Wang, Yiwen Li, Yipeng Hu, Yunguan Fu, Benjamin Gorman, Hans Johnson, Brad Genereaux, Barbaros S. Erdal, Vikash Gupta, Andres Diaz-Pinto, Andre Dourson, Lena Maier-Hein, Paul F. Jaeger, Michael Baumgartner, Jayashree Kalpathy-Cramer, Mona Flores, Justin Kirby, Lee A. D. Cooper, Holger R. Roth, Daguang Xu, David Bericat, Ralf Floca, S. Kevin Zhou, Haris Shuaib, Keyvan Farahani, Klaus H. Maier-Hein, Stephen Aylward, Prerna Dogra, Sebastien Ourselin, and Andrew Feng. Monai: An open-source framework for deep learning in healthcare, 2022. URL <https://arxiv.org/abs/2211.02701>.
- [2] Jieneng Chen, Yongyi Lu, Qihang Yu, Xiangde Luo, Ehsan Adeli, Yan Wang, Le Lu, Alan L. Yuille, and Yuyin Zhou. Transunet: Transformers make strong encoders for medical image segmentation, 2021. URL <https://arxiv.org/abs/2102.04306>.
- [3] Liang-Chieh Chen, Yukun Zhu, George Papandreou, Florian Schroff, and Hartwig Adam. Encoder-decoder with atrous separable convolution for semantic image segmentation, 2018. URL <https://arxiv.org/abs/1802.02611>.
- [4] Fabio Garcea, Alessio Serra, Fabrizio Lamberti, and Lia Morra. Data augmentation for medical imaging: A systematic literature review. *Computers in Biology and Medicine*, 152:106391, 2023.



ISSN 0010-4825. doi: <https://doi.org/10.1016/j.combiomed.2022.106391>. URL <https://www.sciencedirect.com/science/article/pii/S001048252201099X>.

- [5] Ali Hatamizadeh, Yucheng Tang, Vishwesh Nath, Dong Yang, Andriy Myronenko, Bennett Landman, Holger R Roth, and Daguang Xu. Unetr: Transformers for 3d medical image segmentation. In *Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision*, pages 574–584, 2022.
- [6] Fabian Isensee, Jens Petersen, Andre Klein, David Zimmerer, Paul F. Jaeger, Simon Kohl, Jakob Wasserthal, Gregor Koehler, Tobias Norajitra, Sebastian Wirkert, and Klaus H. Maier-Hein. nnu-net: Self-adapting framework for u-net-based medical image segmentation, 2018.
- [7] Ozan Oktay, Jo Schlemper, Loic Le Folgoc, Matthew Lee, Mattias Heinrich, Kazunari Misawa, Kensaku Mori, Steven McDonagh, Nils Y Hammerla, Bernhard Kainz, Ben Glocker, and Daniel Rueckert. Attention u-net: Learning where to look for the pancreas, 2018. URL <https://arxiv.org/abs/1804.03999>.
- [8] Olaf Ronneberger, Philipp Fischer, and Thomas Brox. U-net: Convolutional networks for biomedical image segmentation, 2015. URL <https://arxiv.org/abs/1505.04597>.
- [9] Yucheng Tang, Dong Yang, Wenqi Li, Holger Roth, Bennett Landman, Daguang Xu, Vishwesh Nath, and Ali Hatamizadeh. Self-supervised pre-training of swin transformers for 3d medical image analysis, 2022. URL <https://arxiv.org/abs/2111.14791>.
- [10] Julia Wolleb, Robin Sandkühler, Florentin Bieder, Philippe Valmaggia, and Philippe C. Cattin. Diffusion models for implicit image segmentation ensembles, 2021. URL <https://arxiv.org/abs/2112.03145>.
- [11] Junde Wu, Wei Ji, Huazhu Fu, Min Xu, Yueming Jin, and Yanwu Xu. Medsegdiff-v2: Diffusion based medical image segmentation with transformer, 2023. URL <https://arxiv.org/abs/2301.11798>.
- [12] Zhoubing Xu, Adam Gertz, Rebecca Baucom, Benjamin Poulou, Richard Abramson, and Bennett Landman. Miccai multi-atlas labeling beyond the cranial vault—workshop and challenge. In *MICCAI Multi-Atlas Labeling Beyond Cranial Vault — Workshop Challenge*, 2015.

- [13] Zongwei Zhou, Md Mahfuzur Rahman Siddiquee, Nima Tajbakhsh, and Jianming Liang. Unet++: A nested u-net architecture for medical image segmentation, 2018.